Atividade Prática — Inteligência Artificial

Explorando o Algoritmo KNN

Dataset: Wine Quality (Red + White)

Nome(s) do(s) integrante(s):

David Ramalho Teixeira de Carvalho – RGM: 34262407

1. Análise Exploratória

1.1 Descrição do Dataset

O dataset utilizado neste trabalho é o Wine Quality, disponibilizado publicamente no Kaggle. Ele reúne informações sobre vinhos tintos e brancos de origem portuguesa, combinados em um único arquivo (winequalityN.csv). Ao todo, o dataset contém 6.497 amostras e 13 colunas.

Característica	Valor
Total de amostras	6.497
Número de colunas	13 (12 atributos + 1 alvo)
Vinhos tintos	1.599
Vinhos brancos	4.898
Valores nulos	38 (distribuídos em 7 colunas)

1.2 Atributos

Os atributos do dataset representam propriedades físico-químicas dos vinhos, medidas em laboratório:

Atributo	Descrição
type	Tipo do vinho: red (tinto) ou white (branco)
fixed acidity	Acidez fixa (g/dm³)
volatile acidity	Acidez volátil — vinagre; valores altos indicam má qualidade
citric acid	Ácido cítrico — contribui para frescor e sabor
residual sugar	Açúcar residual após a fermentação (g/dm³)
chlorides	Teor de sal no vinho
free sulfur dioxide	Dióxido de enxofre livre — conservante natural
total sulfur dioxide	Dióxido de enxofre total
density	Densidade do vinho (g/cm³)
pH	Nível de acidez (escala 0–14)
sulphates	Aditivo que contribui para SO_2
alcohol	Teor alcoólico (% vol)
quality	Nota de qualidade original (3 a 9) — coluna alvo

1.3 Distribuição das Notas de Qualidade

A coluna quality contém notas de 3 a 9, atribuídas por especialistas. A distribuição é concentrada nas notas intermediárias (5, 6 e 7), com poucas amostras nos extremos (notas 3, 4, 8 e 9). O gráfico abaixo ilustra essa distribuição:

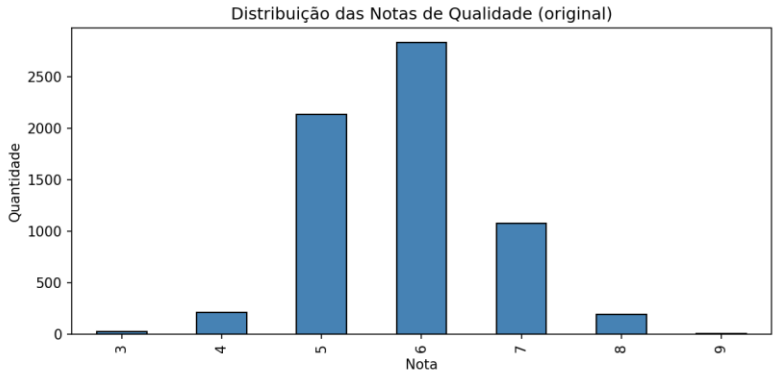

1.4 Criação das Classes

Como o objetivo da atividade é classificação, as notas originais foram agrupadas em três classes:

Classe	Notas agrupadas	Quantidade
Baixa	3, 4, 5	2.384 amostras (~37%)
Média	6, 7	3.915 amostras (~60%)
Alta	8, 9	198 amostras (~3%)

Observa-se que as classes são desbalanceadas, com a classe Alta representando apenas 3% das amostras. Isso pode dificultar o aprendizado do modelo para vinhos de qualidade alta, o que será analisado na conclusão.

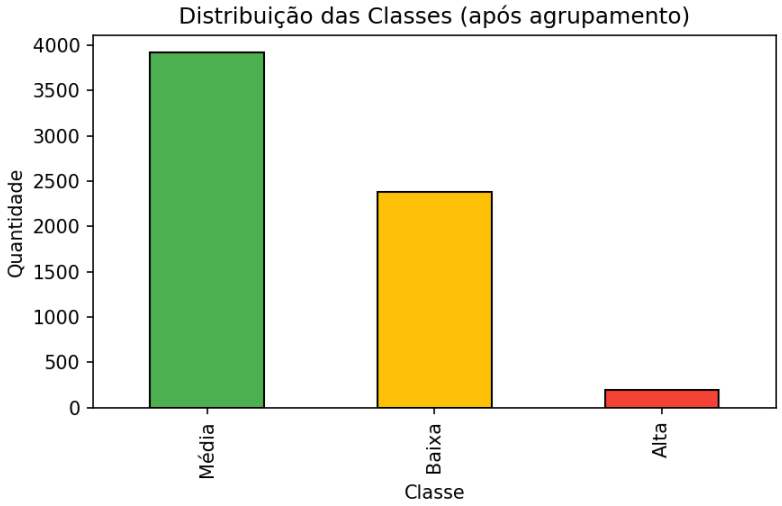

2. Justificativa do Pré-processamento

O pré-processamento é uma etapa fundamental para o KNN, pois o algoritmo é diretamente afetado pela qualidade e escala dos dados. As seguintes técnicas foram aplicadas:

2.1 Tratamento de Missing Values (Imputação pela Mediana)

Problema identificado: o dataset possui 38 valores ausentes distribuídos em 7 colunas, como fixed acidity (10 nulos), pH (9 nulos) e volatile acidity (8 nulos).

Técnica aplicada: imputação pela mediana com SimpleImputer do scikit-learn.

Justificativa: remover as linhas com nulos reduziria o dataset sem necessidade. A mediana foi escolhida por ser robusta a valores extremos (outliers), ao contrário da média, que poderia ser distorcida por vinhos com propriedades atípicas.

2.2 Codificação de Variável Categórica (One-Hot Encoding)

Problema identificado: a coluna type contém valores textuais (“red” e “white”). O KNN não consegue calcular distâncias entre valores de texto.

Técnica aplicada: One-Hot Encoding com pd.get_dummies(), que converteu a coluna em uma nova coluna binária type_white (1 = branco, 0 = tinto).

Justificativa: o One-Hot Encoding foi preferido ao Label Encoding porque a codificação numérica (0 e 1 para tinto e branco) não implica uma ordem ou hierarquia entre os tipos de vinho — apenas indica a presença ou ausência de uma categoria.

2.3 Normalização (StandardScaler)

Problema identificado: os atributos possuem escalas muito diferentes. Por exemplo, total sulfur dioxide varia de 0 a 300, enquanto pH varia de 2,8 a 4,0. Sem normalização, atributos com valores maiores dominariam o cálculo de distância, tornando os demais irrelevantes.

Técnica aplicada: StandardScaler, que transforma cada atributo para ter média ≈ 0 e desvio padrão ≈ 1.

Justificativa: esta é a etapa mais crítica para o KNN. Após a padronização, todos os atributos contribuem igualmente para o cálculo da distância, independentemente de sua escala original. O gráfico abaixo mostra a distribuição do atributo alcohol antes e depois da normalização:

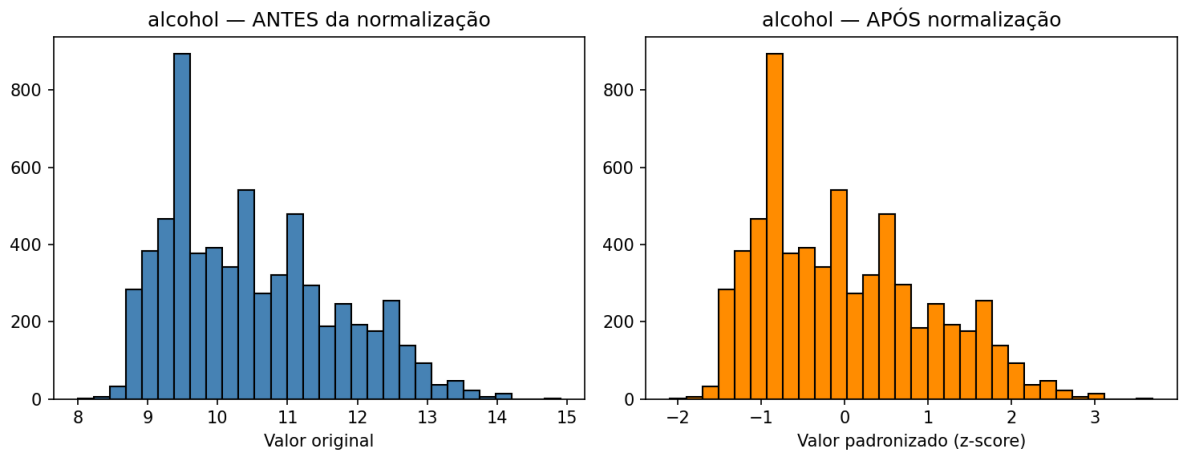

Após a normalização, o atributo mantém exatamente a mesma distribuição (formato do gráfico), mas agora centrado em zero — confirmando que a técnica reescalou os dados sem distorcer sua forma.

2.4 Divisão Treino/Teste Estratificada (80/20)

O dataset foi dividido em 80% para treino (5.197 amostras) e 20% para teste (1.300 amostras), utilizando o parâmetro stratify para garantir que a proporção das três classes seja mantida em ambos os conjuntos.

Justificativa: sem estratificação, a classe Alta (apenas 3% do dataset) poderia ficar sub-representada no conjunto de teste, comprometendo a avaliação real do modelo.

3. Gráfico de Desempenho

O script testou todas as combinações de K (de 1 a 15) com quatro métricas de distância: Euclidiana, Manhattan, Chebyshev e Minkowski (p=3). Para cada combinação, foi calculada a acurácia no conjunto de teste.

O gráfico abaixo apresenta a evolução da acurácia em função do valor de K para cada distância:

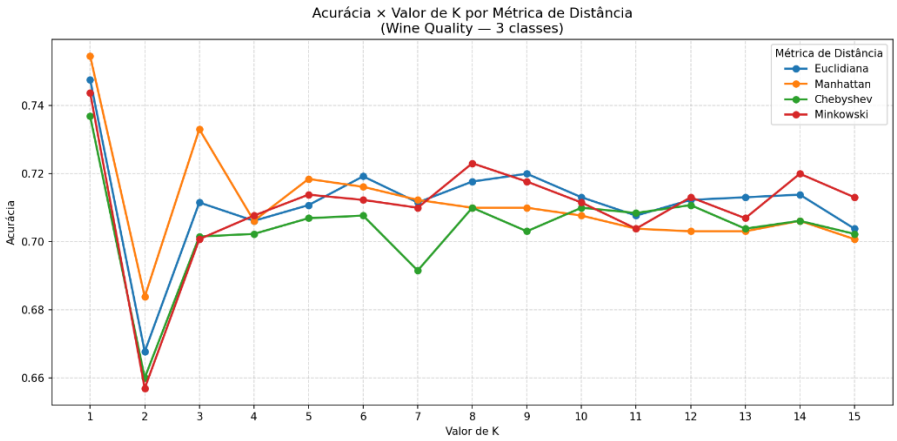

Além do gráfico principal, a matriz de confusão da melhor combinação encontrada está apresentada abaixo, mostrando detalhadamente os acertos e erros por classe:

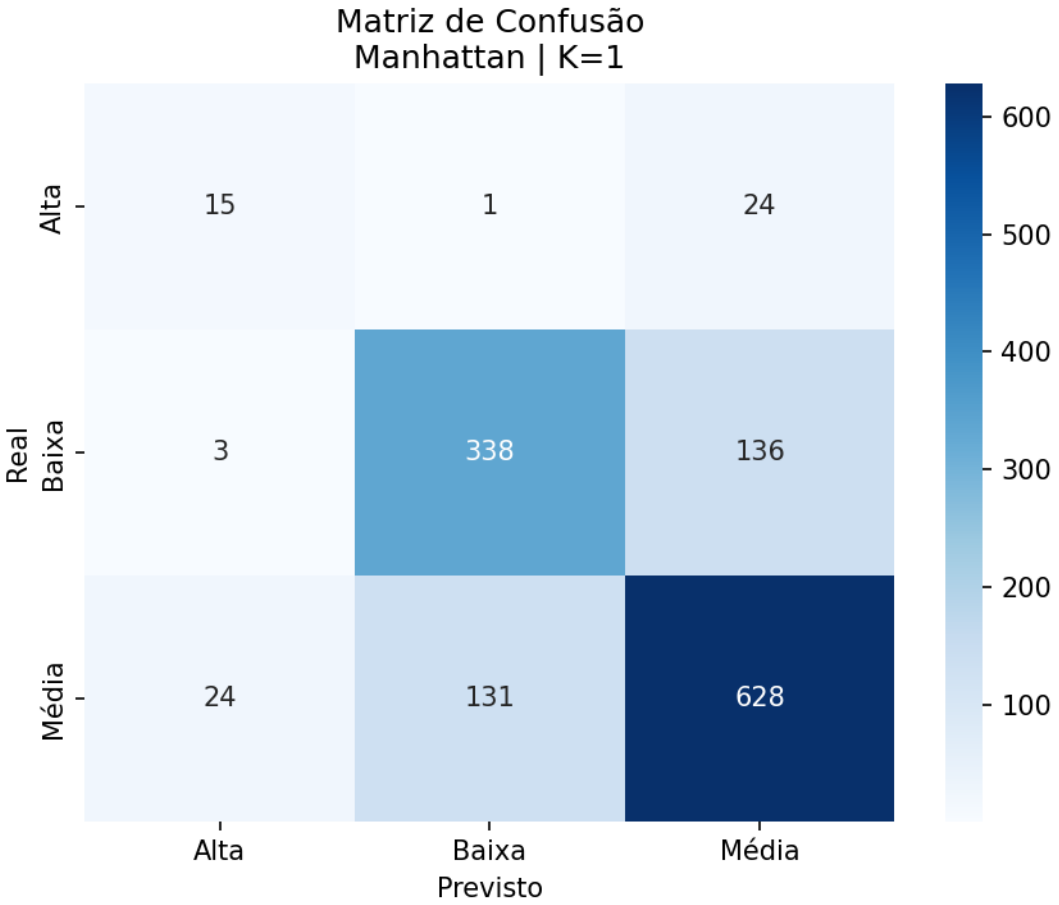

4. Conclusão

4.1 Melhor Combinação Encontrada

Após testar 60 combinações (15 valores de K × 4 distâncias), a melhor configuração encontrada foi:

Parâmetro	Valor
Distância	Manhattan
Valor de K	1
Acurácia	0.7546

4.2 Análise de Overfitting

Com K=1, o modelo utiliza apenas o vizinho mais próximo para classificar cada amostra, tornando-o extremamente sensível ao conjunto de treino. Isso caracteriza overfitting: o modelo “memoriza” os dados de treino em vez de aprender padrões generalizáveis.

Nos resultados obtidos, observamos que com K=1 as acurácias variaram entre 0.7369 e 0.7546 dependendo da distância, enquanto com K=15 ficaram entre 0.7008 e 0.7131. A diferença positiva consistente em todas as quatro métricas indica sinais de overfitting com K baixo — o modelo se ajusta demais às amostras de treino e perde um pouco da capacidade de generalização. A queda mais acentuada foi observada na distância Manhattan (diff: +0.0538). Por outro lado, K=15 também não representou a melhor configuração, sugerindo que o valor ideal de K se encontra em uma faixa intermediária, conforme evidenciado no gráfico de desempenho

4.3 Considerações Finais

A classe Alta (notas 8 e 9) representa apenas 3% do dataset, o que dificultou sua classificação correta pelo modelo — como evidenciado na matriz de confusão. Este é um problema clássico de desbalanceamento de classes.

As distâncias Euclidiana e Manhattan tendem a apresentar desempenho similar em datasets com atributos padronizados. A distância Chebyshev, por considerar apenas a maior diferença entre atributos, mostrou-se menos adequada para este problema.

De forma geral, o pré-processamento — especialmente a normalização — foi essencial para o bom desempenho do KNN, confirmando que a qualidade dos dados tem impacto direto nos resultados do algoritmo.